

文章编号: 1007-1423(2024)15-0104-07

DOI: 10.3969/j.issn.1007-1423.2024.15.019

基于 LangChain 和 ChatGLM 的高校财务问答系统研究与实现

蔡振华*, 王燕贞, 杨 净

(漳州职业技术学院电子信息学院, 漳州 363000)

摘要: 首先对高校财务网站上的文档进行了搜集、整理和加工, 形成了一个本地知识库。接着, 结合该知识库, 构建了一个基于 LangChain 和 ChatGLM 的高校财务问答系统。为了评估系统的性能, 由高校财务工作人员、教师和学生志愿者组成的评测小组对系统进行了详细的测试、评估与分析。测试结果显示, 该问答系统在准确性、可解释性和响应速度等方面表现优异, 尤其是在科研经费管理、学生业务、工薪劳务等领域的问答已接近实用水平。然而, 系统在知识库完备性、问题相关知识检索、基于知识生成有效回答等方面仍存在不足, 这些方面是未来研究的重点。相关研究工作为提升高校财务部门的服务能力和水平提供了一种新的解决方案, 同时也为大语言模型在数字校园建设方面的研究与应用提供了有益的参考。

关键词: LangChain; ChatGLM; LLM; 大语言模型; 财务问答; 知识库问答; 问答系统; 对话系统

0 引言

目前, 高校的财务部门普遍存在咨询压力大、服务不及时等问题^[1]。因此, 开发一款高效、便捷的高校财务问答系统变得至关重要。国内外已有许多关于问答系统的研究, 但针对高校财务领域的问答系统研究尚不多见, 对于高校财务问答系统的研究仍然存在一些问题和挑战^[2]。首先, 现有的高校财务问答系统大多数是基于规则或者简单的知识库进行设计的, 这些系统在处理复杂问题时往往无法给出准确的答案; 其次, 由于高校财务涉及的知识领域广泛, 包括会计、审计、税务等多个方面, 因此, 如何有效地整合这些知识并构建一个统一的知识库成为了一个重要的问题; 此外, 随着大规模语言模型(LLM)等人工智能技术的发展, 如何利用这些前沿技术提高高校财务问答系统的性能也是一个值得研究的问题^[3-4]。

1 基于大语言模型的知识库问答技术

基于大语言模型的本地知识库问答^[5-6], 其实现原理如图 1 所示。




图 1 基于大语言模型的本地知识库问答

首先, 本地知识库文档通过非结构化文本加载器转化为文本, 再经过文本分割器切分为较小的文本块; 其次, 将切分后的文本块送入嵌入模型得到其向量表示, 存入向量数据库中

收稿日期: 2024-01-31 修稿日期: 2024-03-27

基金项目: 2022 年度福建省中青年教育科研项目(JAT220678); 2022 年漳州职业技术学院职业教育专项课题(ZZY2022Z34); 2022 年漳州职业技术学院博士科研启动基金(ZZYB2201)

作者简介: *通信作者: 蔡振华(1984—), 男, 福建漳州人, 博士, 讲师, 研究方向为对话系统、自然语言处理、大语言模型, E-mail: jinhuachua@foxmail.com; 王燕贞(1980—), 女, 福建漳州人, 硕士, 副教授, 研究方向为软件开发、人工智能、机器学习; 杨净(1994—), 女, 福建漳州人, 硕士, 助教, 研究方向为大数据分析、数据挖掘、深度学习

(流程1~6);再将用户的提问送入嵌入模型得到相应的问题向量,经过语义相似度计算,从向量数据库中检索出与问题相关的文本块(流程8,9,10,7,11);最后,用问题相关文本块填充提示词模板生成提示词,输入大语言模型,返回问题的回答(流程12~15)。

上述过程涉及的关键技术包括 LangChain、ChatGLM,以及向量数据库。

1.1 LangChain

大语言模型(LLM)已逐渐成为自然语言处理领域的核心。然而,单纯的语言模型无法满足实际的应用需求,而且大语言模型的训练和推理成本很高,很多开发者和企业都无法训练自己的大语言模型。

为了解决这个问题,LangChain 框架提供了一系列工具和 API,帮助开发人员快速构建应用程序和数据管道。组件(Components)和链(chains)是 LangChain 的两个核心概念。“组件”封装了对各种语言模型(如 OpenAI 的 ChatGPT)的交互操作,比如提示管理、提示优化和提示序列化;保存和模型交互时的上下文状态;结构化文档等。将多个不同的组件有序地组织起来,用于执行特定的高阶任务,这就是“链”^[7]。

LangChain 框架大大简化了基于大语言模型的应用程序开发。首先,开发人员需要选择一个大语言模型作为基础模型,例如 OpenAI 的 ChatGPT;然后,使用 LangChain 框架提供的各种组件,组装形成用于执行特定任务的链。一个典型的大语言模型应用(即执行特定任务的链)包括构建提示词、调用语言模型、输出结果解析与重组等步骤。本文实现的高校财务问答系统就是基于 LangChain 框架开发的。

1.2 ChatGLM

ChatGLM 参考了 ChatGPT 的设计思路,在千亿基座模型 GLM-130B 中注入了代码预训练,通过有监督微调(Supervised Fine-Tuning)等技术实现人类意图对齐。GLM-130B 基于 General Language Model(GLM)架构,不同于 BERT、GPT-3 以及 T5 的架构,GLM 是一个包含多目标函数的自回归预训练模型^[8-9]。

ChatGLM-6B 是一个开源的、支持中英双语

的对话语言模型,使用与 ChatGLM 相同的技术,具有 62 亿参数。FP16 半精度下,ChatGLM-6B 需要至少 13 GB 的显存进行推理,结合模型量化技术,这一需求可以进一步降低到 10 GB (INT8)和 6 GB (INT4),使得开发人员可以在消费级的显卡上进行本地部署。

ChatGLM3-6B 是开源中英双语对话模型 ChatGLM-6B 的第三代版本,采用了更多样的训练数据、更充分的训练步数和更合理的训练策略,在语义、数学、推理、代码、知识等不同角度的数据集上测评性能均有显著提升。本文实现的高校财务问答系统即采用 ChatGLM3-6B 作为基础模型。

1.3 向量数据库

向量数据库是一种专门用于存储、管理、查询、检索向量的数据库,常用于人工智能、机器学习、数据挖掘、对话系统等领域。

常见的向量数据库可以分为三类^[10-11]:一类是纯向量数据库,如 Facebook 开发的 Faiss (Facebook AI Similarity Search),其核心是倒排索引和聚类算法;另一类是建立在纯向量数据库基础上的优化和扩展,如构建在 Faiss、Annoy、HNSW 等向量搜索库基础上的 Milvus,采用共享存储架构,存储计算完全分离,计算节点支持横向扩展;最后一类是基于原有 SQL 或 NoSQL 数据库的插件,如 PostgreSQL 数据库的插件 PGVector,使用熟悉的 SQL 查询语法进行向量操作,这简化了具有 SQL 知识和经验的开发人员使用向量数据库的过程。

本文构建的高校财务问答系统不涉及高并发、高可用性问题,也不考虑与原有 SQL 或 NoSQL 数据库的兼容,因此我们选用纯向量数据库 Faiss。

2 高校财务问答系统设计与实现

2.1 数据集准备与预处理方法

2.1.1 数据集准备

我们通过“大学财务问答”“学院财务问答”等短语在百度、必应等搜索引擎中检索与高校财务问答相关的文档。发现高校财务网站上提供的文档大致可以分为以下三类:①学校

发布的财务相关文件、管理规定、法律法规等；
②学校财务部门整理的手册或指南，按不同类别介绍具体事项的流程、所需的材料等；③学校财务部门搜集整理的常见问题及回答。

大部分高校的财务网站都提供第一类文档(财务相关文件、管理规定等)，少部分高校的财务网站发布第二类文档(财务手册或办事指南)，仅在很少的高校财务网站上查找到第三类文档(财务常见问题及回答)。

本文采用第一类和第二类文档构建本地知识库，实现高校财务问答系统；保留第三类文档作为测试用例，用于验证高校财务问答系统的准确性和有效性。

按照上述规划，我们选择三类文档都较为齐全的一所高校财务网站，将其文档进行脱敏处理和归类整理，形成最终的数据集。最终构建的本地知识库包含15个类别、98个文件，共计39.05万字，具体见表1。

测试用例包含6个大类、21个小类，共计202个问题(如图2所示)。其中，报销(占比

65%)、工资劳务(占比17%)、科研经费管理(占比8%)涵盖了90%的常见问题(如图3所示)。

表 1 本地知识库文档类别及数量 单位:个

文件类别	文件数量
报销规定	2
差旅费规定	11
会议费(培训费)规定	6
公务接待规定	3
公务卡管理	6
资金管理	9
经济管理	5
二级财务管理	3
预决算管理	9
内部控制	3
科研经费管理	12
专项管理	8
收费及票据管理	9
学生业务	11
合同管理	1




图 2 测试问答对各类别数量




图3 测试问答对各类别分布情况

2.1.2 数据预处理

(1) 加载本地的文档

首先，将本地的文件读取为文本的形式。通过LangChain中的document loader加载本地文档，它支持txt、markdown、pdf等常见的文本格式。对于扫描类的文档，我们使用PaddleOCR将扫描图像识别为文本。加载后的文档转化为LangChain的Document对象，包含文本内容、文件路径、页数等信息。

(2) 执行文本的拆分

由于语言模型的输入长度是有限的，我们通常无法将一整篇本地的文档直接输入给语言模型，所以需要先将文档切割为较短的片段，然后从中筛选出与提问有关的文档片段，最后再结合具体的提问内容一起提供给语言模型。我们从LangChain中的CharacterTextSplitter类派生，实现下面的文本拆分逻辑：先用中文的句号、问号、叹号等标点符号将文档拆分为句子；如果划分后的句子长度超过设定的阈值（如100个字符），再用中文的逗号、分号等标点符号将语句划分拆分为更细的文本片段。下面为部分核心代码：

```
import re
from langchain.text_splitter import CharacterTextSplitter
class MyTextSplitter(CharacterTextSplitter):
    def split_text(self, text: str) -> List[str]:
        # 先用中文的句号、问号、叹号等标点符号
        # 将文档拆分为句子
        pattern_sentence = re.compile('([.?!。!?]
        ["'"]]|0,2|(?=[“”‘’]{1,2}|$))')
        sentences = pattern_sentence.split(text)
```

```
# 如果划分后的句子长度超过设定的阈值
# (如100个字符),
# 再用中文的逗号、分号等标点符号将语句划分
# 拆分为更细的文本片段
fragments = []
for sentence in sentences:
    if len(sentence) > self.max_sentence_len:
        _fragments = re.sub(r'([,。;]{1,2}|$))'
        ([^,。;])', r'\1\n2', sentence).split('n')
        fragments.extend(_fragments)
    else:
        fragments.append(sentence)
return fragments
```

2.2 基于大语言模型的本地知识库问答

2.2.1 构建向量数据库

对前面拆分得到的文本段落利用嵌入(embedding)模型转化为向量，存入到向量数据库Faiss中，形成本地知识库的本地。前面拆分得到的文本段落，以及对应的向量全部都存储在向量数据库中。

2.2.2 语义相似度检索

在文段拆分完成之后，我们需要根据用户的提问，通过语义检索的方式，筛选出与之相关的文段。先通过与文本拆分相同的嵌入模型将用户的提问转化为对应的查询向量。然后，再将查询向量与向量数据库中已有的向量进行匹配，检索出相关度最高的 k 个文档片段。 k 为预先设定的参数，在我们实现的高校财务问答系统中， k 值取为6，即最多获取6个与用户提问相关的文段。

2.2.3 提示词工程问答

在完成了文段筛选之后我们就要构建输入给语言模型的提示词(prompt)，即将匹配文本、用户的提问共同加入到提示词模板当中，形成提交给语言模型的提问内容。然后，把提问内容发送给语言模型获得基于文档内容的回答。

下面是本文所采用的提示词模板，开头的引导语让大语言模型扮演高校财务的工作人员，{question}和{contexts}将分别替换为用户的提问和匹配的文本。

```
prompt_template = """
```

现在你的身份是一名耐心、专业的高校财务处的工作人员，
你十分乐于为学校老师和同学解答关于大学财务工作的各种问题。

请你认真回答问题：{question}

你在回答问题时，需要结合大学财务工作的基本常识，并重点根据以下信息来回答：

```
{contexts}  
"""
```

上述问答过程通过 LangChain 中的 local_doc_qa 来实现。为避免问答系统对本地知识没有涵盖的内容答非所问误导用户，我们用 temperature 参数来调节语言模型的发散程度，同时通过相关度阈值的限制(如设定为 500)排除与用户提问不相关的文段。最后，在对本地知识库进行检索时，如果系统没有检索出任何相关的文段，则使用固定的模板(而不是语言模型)生成回答，从而使问答系统尽量依据本地知识库来回答问题。

3 性能评估和测试结果分析

3.1 系统测试与评估

我们邀请了2名高校财务部门工作人员、5名教师和3名学生志愿者，组成10人的评测小组对问答系统进行测评。

首先，通过调用系统的 Restful API 获取全部(共202个)测试问题的回答，以及系统检索到的与问题相关的本地知识库文本片段；然后，我们为每位评测人员提供完整的本地知识库文档，每个测试问题的参考答案、系统回答，以及系统检索出的本地知识库相关文本片段，邀请每位评测人员各自独立为每个问题的系统回答打分。

评分标准如下：0分，系统回答与参考答案无关，对提问者开展相应的工作没有帮助，甚至还会造成误导；1分，系统回答与参考答案部分匹配，出现较多错漏或多余的内容，提问者难以根据系统回答开展相应的工作；2分，系统回答与参考答案较为匹配，虽然遗漏或出现一些多余的内容，但不影响提问者根据系统回答正确开展相应的工作；3分，系统回答与参考答案匹配度很高，几乎没有错漏或多余的内容。

最后，我们对每个测试问题，计算全部评测人员的打分的平均分，作为该问题的最终得

分。表2为不同类别问题的系统回答平均得分情况。系统在回答科研经费管理、学生业务、工薪劳务方面的问题得分较高，在回答报销、收入、其他财务事项方面的问题得分较低。

表2 不同类别问题的系统回答得分情况 单位:分

问题分类	平均分数
报销业务	1.7
收入业务	1.6
科研经费管理	1.9
学生奖助学金与缴费	1.8
工薪、劳务、公积金及涉税事项	1.8
其他财务事项	1.1

3.2 测试结果分析

我们详细分析了得分较低的系统回答，发现以下三类主要问题。

(1) 本地知识库缺失

例如，“其他财务事项”中有一个测试问题是“各科室办公地点及电话是什么？”，由于本地知识库收录的是财务相关的管理规定或政策文件，没有包含具体的办公信息，导致系统无法正确回答该问题。本地知识库中，报销业务和收入业务仅有少量直接相关的文件(见表1)，相关知识缺失或散落在其他的文件中，这在很大程度上影响了这两类问题的回答效果。

(2) 系统无法从知识库中检索出相关信息

例如，对于问题“会议类别主要有哪些？”，系统未能检索出与之相关的信息。但是，当我们人工检索本地知识库时，却发现其中包含回答该问题所需的信息：

第二条 本办法适用于学校举办(含主办、承办)的各类会议，包括国内业务会议、国内管理会议、在华举办国际会议。

国内业务会议是指因教学、科研、研究生教育和学科建设需要举办的业务性会议，包括学术会议、学术论坛、研讨会、评审会、座谈会、答辩会等。

国内管理会议是指除国内业务会议之外的其他国内会议。

在华举办国际会议是指报经教育部外事部门批准的在我国境内举办的国际会议。

(3) 系统无法根据检索出的信息有效地回答问题

例如, 问题“发票报销有时限吗?”, 系统检索出相关信息如下:

文献[1]2023年京州理工大学财务制度汇编.docx

第九条 报销人取得发票后, 须自行在网上进行真伪验证, 并在发票背面签字确认。单张发票金额超过 5000 元(含)的, 须将查询验证结果打印, 作为报销的凭证。

第十条 发票应当及时报销, 当年度发票原则上当年度报销。鉴于年终结账及假期等特殊情况, 未能在当年报销的发票, 使用期限可延长至次年三月底。

尽管检索出的信息已经包含正确回答“鉴于年终结账及假期等特殊情况, 未能在当年报销的发票, 使用期限可延长至次年三月底”, 但系统却只给出一个笼统的回答。

根据已知信息, 发票报销有一定的时限要求, 如果超过了规定的时间限制, 就需要按照规定进行处理。

4 结语

基于 LangChain 和 ChatGLM 的高校财务问答系统具有较强的实用性和创新性。首先, 它能够准确理解用户的财务问题并从本地知识库中快速检索相关信息, 从而提供更加精准的答案; 其次, 它采用了自然语言处理技术, 使得用户可以通过自然语言进行提问, 无需特定的关键词或语法, 使用起来更加便捷; 最后, 本系统可以为高校财务部门提供一种新型的服务模式, 提高服务质量和效率, 同时也可以提升师生的满意度。

未来我们计划从以下三个方面展开进一步研究:

(1) 促进制度完善

系统未能正确回答的问题中, 有很大比例是由于本地知识库缺失导致的。根据这些问题, 高校财务部门可以有针对性地补充、完善相关的管理规定或制度文件。

(2) 优化知识检索

本文的知识库检索采用语义相似度的方法, 缺乏知识的层次结构, 后续的研究考虑通过层次聚类的方法构建知识树, 结合语义相似度提

升知识检索的准确率和召回率。

(3) 增加模型微调

本文的方法是在回答模板中附加了与问题相关的知识库信息, 但并未对底层的语言模型本身进行任何优化工作, 这导致部分问题虽然系统已经在知识库中检索出相关的信息, 但系统却无法给出令人满意的回答。后续的研究, 我们将针对高校财务问答的业务领域, 编制高质量的问答对, 然后用这些标注数据对模型进行微调。

参考文献:

- [1] 张慧丽, 田书源, 徐宇. A 高校立足科研“放管服”改革的财务信息化建设[J]. 财务与会计, 2022(23): 63-66.
- [2] 董森. 基于人工智能技术的高校智慧财务系统架构研究[J]. 会计之友, 2023(12): 26-31.
- [3] 文森, 钱力, 胡懋地, 等. 基于大语言模型的问答技术研究进展综述[J]. 数据分析与知识发现: 1-17. <http://kns.cnki.net/kcms/detail/10.1478.G2.20231110.1612.002.html>.
- [4] 曹书林, 史佳欣, 侯磊, 等. 知识库问答研究进展与展望[J]. 计算机学报, 2023, 46(3): 512-539.
- [5] 王翼虎, 白海燕, 孟旭阳. 大语言模型在图书馆参考咨询服务中的智能化实践探索[J]. 情报理论与实践, 2023, 46(8): 96-103.
- [6] 金源, 魏振, 李成智. 基于 ChatGPT 的问答式财务知识库构建与应用[J]. 财会月刊, 2023, 44(17): 46-51.
- [7] PANDYA K, HOLIA M. Automating customer service using LangChain: building custom open-source GPT Chatbot for organizations [EB/OL]. arXiv: 2310.05421, 2023.
- [8] ZENG A, LIU X, DU Z, et al. GLM-130B: an open bilingual pre-trained model [EB/OL]. arXiv: 2210.02414, 2023.
- [9] DU Z, QIAN Y, LIU X, et al. GLM: general language model pretraining with autoregressive blank infilling[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin, Ireland: Association for Computational Linguistics, 2022: 320-335.
- [10] PAN J J, WANG J, LI G. Survey of vector database management systems [EB/OL]. arXiv: 2310.14021, 2023.
- [11] TAIPALUS T. Vector database management systems: Fundamental concepts, use-cases, and current challenges [J]. Cognitive Systems Research, 2024, 85: 101216.

Research and implementation of a financial question answering system for universities based on LangChain and ChatGLM

Cai Zhenhua*, Wang Yanzhen, Yang Jing

(School of Electronic Information, Zhangzhou Institute of Technology, Zhangzhou 363000, China)

Abstract: The research begins by collecting, organizing, and processing documents from university financial websites, resulting in the establishment of a local knowledge base. This knowledge base is then utilized to construct a question-answering system for university finance, which is based on LangChain and ChatGLM. To evaluate the system's performance, a panel consisting of university financial staff, teachers, and student volunteers has conducted detailed testing, assessment, and analysis of the system. The test results demonstrate that the question-answering system excels in terms of accuracy, interpretability, and response speed, especially in the areas of research funding management, student services, and payroll services, where it has reached near-practical levels of functionality. However, the system still has deficiencies in knowledge base completeness, retrieval of relevant knowledge for questions, and generation of effective answers based on knowledge, which are the focus of future research. The research efforts provide a novel solution for enhancing the service capabilities and levels of university financial departments and also offer valuable insights for the research and application of large language models in the development of digital campuses.

Keywords: LangChain; ChatGLM; LLM; large language model; financial question answering; knowledge base question answering; question answering system; dialogue system

~~~~~

(上接第 103 页)

## Design and implementation of industry chain big data platform based on knowledge graph

Wan Yixuan\*, Zhang Fu'an, Zhang Yonglong

(School of Information Engineering, Yangzhou University, Yangzhou 225000, China)

**Abstract:** In order to realize the overall development of digital economic intelligence in industrial parks and improve the functional supporting facilities of intelligent parks, a big data analysis and management platform for industrial chain based on Vue.js framework is designed and implemented based on knowledge graph technology. The platform realizes visual industrial chain knowledge mapping, data big screen, relationship query, data analysis, data management and other functions, targeted to solve the regional industrial development, monitoring and evaluation, investment promotion and other issues. Through the deep mining of industrial chain data, the platform builds industrial chain panorama, provides comprehensive decision-making support services for industrial parks, analyzes the value of the deep-level industrial chain, discovers the potential cooperation and competition among enterprises, promotes exchanges and cooperation among regions, and helps to improve the economic benefits of enterprises.

**Keywords:** industry chain; big data; knowledge graph; Vue.js; platform construction