

基于 LangChain 的 Python 知识问答系统的设计与实现

张宁

(太原师范学院 计算机科学与技术学院, 山西 太原 030619)

摘要: 大模型的发展与应用已成为主流趋势, 作为大模型开发应用的核心编程语言, Python 的重要性持续提升。为助力本科学子高效学习并掌握该编程语言, 文章设计并实现了一款辅助学生学习的问答智能体系统。该系统以 LangChain 框架为核心, 整合本地部署的 DeepSeek 大模型, 结合 Chroma 构建的本地知识向量数据库, 完成对学生提问的分析与智能响应; 同时采用 Vue3 与 FastAPI 框架开发 Web 应用, 为学生提供简洁易用的交互页面。所提实现方案对智能体技术在高校本科教学中的落地应用具有积极的实践意义。

关键词: LangChain; 智能体; 向量数据库; 检索增强生成; 大语言模型

中图分类号: TP311

文献标识码: A

文章编号: 2096-4706 (2026) 05-0066-06

Design and Implementation of Knowledge Question Answering System for Python Based on LangChain

ZHANG Ning

(College of Computer Science and Technology, Taiyuan Normal University, Taiyuan 030619, China)

Abstract: The development and application of large models become a mainstream trend. As the core programming language for the development and application of large models, the importance of Python continues to increase. To help undergraduate students learn and master this programming language efficiently, this paper designs and implements an intelligent Question Answering agent system to assist students in learning. This system takes LangChain framework as the core, integrates the locally deployed DeepSeek large model, and combines the local knowledge vector database constructed by Chroma to complete the analysis and intelligent response to student questions. Meanwhile, Vue3 and FastAPI frameworks are adopted to develop Web applications, providing a simple and easy-to-use interactive page for students. The proposed implementation scheme has positive practical significance for the application of agent technology in undergraduate teaching of colleges and universities.

Keywords: LangChain; agent; vector database; retrieval-augmented generation; Large Language Model

0 引言

在计算机科学与技术专业的本科培养计划中, Python 程序设计作为核心基础课程, 占据着重要的教学地位。随着大模型技术的快速发展与广泛落地, 能否掌握并熟练运用 Python 语言解决实际工程问题, 已成为衡量本科学子专业能力的重要指标^[1]。然而在实际教学过程中, 学生在学习环节会产生各类疑问, 其求助渠道通常为教师、教材及网络资源: 受时间限制, 教师无法为学生提供实时答疑; 教材内容具有局限性, 难以满足学生的个性化学习需求; 网络知识体量庞大且良莠不齐, 学生从中精准获取有效信息需耗费大量时间与精力。

为给学生提供高效、便捷的 Python 知识查询与答疑途径, 本研究以 LangChain 框架为核心, 整合本地部署的大语言模型, 设计并实现了一款 Python 知

识问答系统。通过构建本地检索增强生成 (RAG) 架构, 该系统可结合学生提问, 从本地构建的 Python 知识向量数据库中检索精准的相关知识内容, 经大模型分析整合后给出专业答案, 为学生的 Python 学习过程提供实时、准确的学习支持^[2-3]。

1 系统总体设计

1.1 核心技术选型与依据

本研究选用 LangChain 作为系统核心框架, 借助其提供的组件化工具, 可将大语言模型的通用能力与 Python 领域的专属知识库深度融合, 实现更精准的领域问答效果。大模型采用本地部署方案 (基于 ollama 工具部署), 既能够保证学生提问、学习数据的隐私安全, 又能有效控制开发与使用成本^[4]。向量数据库选用 Chroma, 该数据库具备高效的向量存储与相似性检索能力, 适配本地轻量化部署需求^[5]。

后端采用 FastAPI 框架开发, 为前端提供高性能的访问接口, 该框架原生支持异步调用, 可提升系统

收稿日期: 2026-02-02

的并发处理能力；前端采用 Vue3 框架搭建交互界面，为学生提供友好、流畅的操作体验^[6]。

1.2 系统架构设计

系统整体采用模块化架构设计，各模块协同工作实现完整的问答功能，系统功能模块如图 1 所示。整体架构划分为 4 个核心模块：1) 前端模块：基于 Vue3 技术实现，主要负责提供人机交互页面；2) 后端模块：基于 FastAPI 框架实现，提供 Web 服务，接收前端传递的用户问题，调用智能体模块完成处理，将生成的答案返回至前端；3) 智能体模块：基于 LangChain 框架实现，用于整合大语言模型，自动分析用户问题并调度各类工具生成处理结果；4) RAG 模块：负责构建本地 Python 知识数据库。




图 1 系统功能结构图

本研究的核心为智能体模块与 RAG 模块，两个模块的内部均由多个子模块组成。其中智能体模块包含三个关键子模块，一是系统提示词模块，通过规范化的提示词设计，有效降低大语言模型的幻觉概率；二是 Memory 模块，为系统提供短期记忆能力，是实现多轮对话的核心组件；三是工具模块，为大语言模型拓展功能边界，使其具备代码执行、网络搜索等能力。RAG 模块同样包含三个关键子模块，依次为文档加载模块、文档切分模块与向量存储模块，最终通过 Chroma 创建向量数据库，并将向量化后的 Python 领域文档存储至数据库中；向量数据库构建完成后，可通过检索工具从库中快速检索相关知识，与大语言模型实现无缝整合。

1.3 关键模块设计

1.3.1 大语言模型的部署

本研究基于 Ollama 工具在本地部署大语言模型，Ollama 是一款轻量级的大模型部署工具，具有资源占用低的特点，可在常规硬件条件的计算机上完成大语言模型的部署与运行；同时 Ollama 官方提供了丰富的模型资源，支持用户根据自身硬件条件与实际需求灵活调整部署配置。LangChain 框架中提供了对接 Ollama 的专属接口（位于 langchain_ollama 模块），

可将本地部署的大语言模型无缝集成至 LangChain 框架中，实现对模型功能的灵活调用。此外，本地部署大模型的优势还体现在，所有交互数据均存储在本地，无数据泄漏风险；无须调用第三方大模型 API，有效降低了系统的开发与使用成本^[7]。

1.3.2 提示词模板设计策略

避免大语言模型产生幻觉是本系统的核心设计要求之一，而规范化的系统提示词能够有效降低模型幻觉的发生概率，因此提示词模板的设计与编写需做到严谨、完整，充分保障问题解答的准确性^[8]。本系统采用分层式提示词模板设计策略，以 Markdown 格式编写系统提示词模板，为大语言模型赋予精准的角色定位，模板严格划分为问题类型界定层、上下文信息补充层与答案格式约束层。例如，在问题类型界定层中，通过明确“编程语法”“函数用法”“错误调试”等 Python 学习常见问题类别，帮助模型快速定位问题领域；在上下文信息补充层中设置变量，供智能体插入用户历史对话记录或相关代码片段，增强模型的上下文理解能力；在答案格式约束层中，通过设定标准化的输出结构（如 JSON 格式、代码块形式），强制模型生成规范化的回答，同时明确约束模型对非 Python 编程类问题进行礼貌拒绝。

1.3.3 上下文感知与多轮对话记忆机制设计

为实现系统的上下文感知与多轮对话记忆功能，本系统选用 LangChain 框架提供的 ConversationBufferWindowMemory 组件，该组件是实现短期对话记忆的核心模块，既能够保存用户的近期对话内容，又支持自定义保留最近 N 次对话，在保证对话上下文连贯性的同时，有效节约 token 消耗，降低模型的响应延迟。该记忆机制的核心原理为：通过维护一个动态的对话历史缓冲区，实时记录用户与系统之间的所有交互内容；在每轮对话开始时，将缓冲区中的历史对话内容自动填充到系统提示词模板的指定位置，再传递给大语言模型，使模型能够基于历史对话理解用户当前提问的真实意图。

1.4 工具模块设计

1.4.1 代码解释器工具

为增强系统对 Python 代码的识别、分析与验证能力，本系统在工具模块中集成了 PythonREPLTool 工具，该工具能够直接执行 Python 代码并返回实时运行结果。当用户提出与代码运行结果相关的问题，或提交代码寻求调试帮助时，大模型可通过推理自主决定是否调用该工具：将用户提供的代码片段送入 Python 解释器执行，将运行结果与分析结论一并返回给用户，提升答案的准确性与说服力。

1.4.2 外部 API 调用工具

为解决系统知识库范围有限的问题，使系统能够获取外部网络资源补充知识储备，本系统在工具模块中集成了 TavilySearchResults 工具，该工具为系统提供网络搜索能力。当用户提出的问题超出本地知识库的覆盖范围时，大模型通过推理判断后，将自动调用该工具进行互联网检索，提取相关网页中的关键信息，结合大模型的生成能力形成完整答案，有效拓展系统的知识边界。

1.5 接口与交互设计

本系统采用前后端分离的架构设计模式，后端基于 RESTful 风格的 API 架构开发，使用 FastAPI 框架实现高性能的接口请求处理；前端基于 Vue3 框架，结合 Element-Plus 组件库搭建简洁、实用的交互页面。前后端分离架构的优势为扩展性强：同一套后端服务可对接不同的前端应用，既能满足 PC 端用户的使用需求，也能快速适配移动端开发。

2 矢量知识库构建

2.1 知识源采集与预处理

为构建高质量的 Python 领域知识库，本研究通过多渠道收集权威的 Python 文档资料，包括 Python 官方文档、开源电子书籍、教学过程中整理的课程讲义与习题解答等。收集到的文档资料按文件类型分类，存储至指定文件夹中。LangChain 框架提供了丰富的文档加载器，可适配多种格式的文档文件，通过该类工具能够快速将预先准备的 Python 知识文档加载到系统中；同时 LangChain 还提供了多种不同策略的文档切分器，通过该类工具将加载后的大文档切分为若干个小文本块，既能够避免因文本过长导致的检索效率低下问题，又能保证单个文本块的语义完整性。

2.2 文本嵌入模型选择

切分后的文本块需要转换为计算机可识别的向量表示，该过程需借助文本嵌入模型完成。本系统选用 nomic-embed-text-v2-moe 作为文本嵌入模型，该模型支持 512 长度的 token，适配中等长度文本的检索需求，对中文语义的理解能力优异，可部署到本地 Ollama 环境中，通过该模型可高效完成切分后文本块的向量化转换。

2.3 向量化数据库的构建流程

构建向量化数据库是本系统的核心功能之一，系统通过以下流程实现：首先，利用 LangChain 提供的文本切分器对已加载的文本数据进行分块处理，确保每个文本块长度适中，避免因文本过长导致的语义丢失问题。其次，连接 nomic-embed-text-v2-moe 嵌入模型。最后，创建 Chroma 实例对象，同时将嵌入模型对象与切分后的文档传递给该 Chroma 实例。Chroma 对象会自动创建向量数据库，并将切分后的文档完成向量化处理后保存至数据库中。

3 系统实现

3.1 大模型调用与推理实现

连接本地部署的 DeepSeek 大语言模型是本系统的重要实现步骤之一，整体执行流程如图 2 所示。系统通过导入并实例化 LangChain 提供的 ChatOllama 类，可便捷访问本地部署的 DeepSeek R1 8B 大语言模型，实例化过程中可设置相关超参数，以优化模型输出结果。ChatOllama 实例创建完成后，将整合至 Agent 实例对象中；Agent 实例通过整合系统提示词模板与用户提示词模板，将数据提交至本地大模型生成答案，经结果解析器提取有效结果后，最终反馈至 FastAPI 后端路由函数。




图 2 大模型调用执行流程图

3.2 矢量知识库的构建与检索实现

矢量知识库的构建是基于 LangChain 的 Python 知识问答系统的关键环节，该过程主要包含文档加载、文本分块、嵌入向量生成及向量数据库相似性检索等步骤，构建流程如图 3 所示。首先，从多种

知识源（如 Python 官方文档、在线教程及常见问题解答）中采集数据并加载至系统。LangChain 提供了丰富的文档加载器，如 TextLoader、PyPDFLoader、UnstructuredMarkdownLoader 等，可支持多种格式文档的加载。




图 3 RAG 向量数据库构建流程

文档加载完成后，采用 LangChain 提供的文档切分器对其进行切分，目的是控制查询到的文档信息长度，避免 token 浪费。LangChain 提供多种不同切分策略的切分器，本系统选用 RecursiveCharacterTextSplitter 切分器，该切分器采用递归方式切分文档，在保证文本块长度适中的同时，最大限度保留语义完整性。创建 OllamaEmbeddings 类实例，该实例可访问本地部署的嵌入模型，用于将切分后的文档转换为向量。创建 Chroma 向量数据库实例，整合嵌入模型对象，在数据库创建过程中，同步将文档向量保存至数据库内。

3.3 工具功能的编码实现

大语言模型相当于人类的大脑，可执行高效的思考过程，但缺乏实际行动能力。工具模块的引入，使其能够执行特定任务。LangChain 提供 Tool 类，支持用户将自定义工具注册至 Agent 中，Agent 可根据大模型的推理结果调用对应工具，工具调用过程如图 4 所示。本系统为实现用户提交代码的执行功能，在 Agent 中注册了 PythonREPLTool 工具；为保障工具安全执行，系统配套实现了严格的安全检查机制。同时，Agent 中还注册了 TavilySearchResults 工具，当大模型遇到知识欠缺情况时，会调用该工具进行互联网搜索，获取充足知识以解答用户问题。在多轮

对话场景中，大模型将根据用户问题内容进行推理，最终将结果封装为 AIMessage 对象返回给 Agent，Agent 依据该结果判断是否调用工具。例如，当检测到问题包含“运行代码”“执行命令”等关键词时，大模型会返回工具调用指令，Agent 据此调用对应特定工具。

3.4 接口层实现

接口层是连接用户与 Python 知识问答系统的核心桥梁^[9]。本系统选用 FastAPI 作为 Web 框架，其具备高性能、易用性的特点，且支持异步调用^[10]。API 端点设计主要包括路由定义、请求处理及结果返回 3 个核心部分：首先，定义路由用于接收前端发送的用户问题；处理请求时，系统将用户问题传递至路由处理函数；路由处理函数调用智能体，由智能体协调提示词模板、大模型、知识库等模块完成处理，处理完成后，智能体将响应结果返回至路由处理函数，路由处理函数提取响应内容并封装为 JSON 格式，反馈给前端用户。为提升用户体验，接口层额外实现了输入验证、错误处理、日志记录等辅助功能。前端页面基于 Vue3 框架整合 Element-Plus 技术开发，通过页面收集用户问题，借助 Axios 工具通过 API 接口提交至 FastAPI 路由处理函数，最终展示响应结果，页面设计遵循简洁易用的原则，用户交互界面如图 5 所示。




图 4 工具调用流程




图 5 用户交互界面

4 结 论

本系统基于本地部署的大模型，结合 LangChain 框架构建了知识问答智能体系统，为本科 Python 程序设计课程教学提供了创新性支持。首先，系统通过集成大语言模型与 Chroma 向量数据库，提升了知识问答的准确性，可从多种知识源中检索并生成与用户问题高度相关的答案。其次，系统支持多轮对话，通过上下文感知与对话记忆机制的设计，使大模型在连续对话中能够精准把握用户意图，提供连贯的交互体验。此外，系统集成了代码解释器与外部 API 调用工具，进一步拓展了功能边界，可执行 Python 代码或通过搜索引擎获取更广泛信息，辅助学生解决复杂编

程问题。本研究为智能体与大模型技术在本科教学中的应用进行了有益探索。

参考文献：

[1] 苏小红，何钦铭. 人工智能赋能教与学场景和模式革新的探索——以程序设计课程为例 [J]. 中国大学教学，2025 (6)：65-72.
[2] 华子荀，王伟，廖绿优，等. 生成式人工智能 RAG 路径赋能课程设计：课程小语言模型构建与教学实践 [J]. 广东第二师范学院学报，2025，45 (5)：31-44.
[3] 蔡振华，王燕贞，杨净. 基于 LangChain 和 ChatGLM 的高校财务问答系统研究与实现 [J]. 现代计算机，2024，30 (15)：104-110.
[4] 杨彬，肖鸿儒，高尚，等. 基于协同专家系统的建筑施工大语言模型问答系统 [J]. 同济大学学报（自然科学版），2026，54 (1)：13-21，30. (下转 77 页)

次) 机台可维持常规保养, 但需对比历史数据确认是否正
常损耗。所有检修记录需同步更新至设备档案, 以便追
踪分析故障。”




图 4 2025 年 3—5 月机台运行效率趋势分析图




图 5 机台维修次数统计图

根据建议, 经过设备检修保养后, 4 月 (红色实线) 整体表现适中, 第 3 周达峰值 92.5%, 但第 4 周回落至 91.2%, 建议总结高效周的最佳实践并推广, 同时加强日常维护以减少波动; 5 月 (绿色实线) 整体表现最优, 前 2 周升至 93.2%, 第 3 周下降至 89.0%, 第 4 周又稳定在了 92.2%。图 4 数据清晰显示, 4 月和 5 月的机台运行效率较 3 月显著提升, 验证了报告分析及改进方案的有效性。图 5 统计了 2025 年 3 月第 4 周维修频次异常偏高的部分机台设备, 这些可视化分析结果将有助于识别生产瓶颈并指导优化决策。

5 结 论

该系统创新性地构建了一套面向数字化制造场景的多维度产能分析报告生成系统, 通过整合多源异构数据采集、实时动态分析等关键技术, 实现了从生产状态感知到优化决策的全流程闭环管理。相比传统人工分析模式, 该系统将产能报告的生成周期从数天缩短至数分钟, 并将问题识别的维度从单一的设备状态扩展至人员与机器的多维关联分析, 使生产效率评估

更为全面, 异常响应机制也显著提升。

尽管该系统取得了一定成果, 但在实际应用中仍存在
一些不足。未来的工作将重点围绕以下方向展开:
1) 引入预测性维护模型, 基于历史数据预测设备故障,
变被动响应为主动预防; 2) 探索与 MES/APS 系统的
深度集成, 实现从分析建议到生产计划自动调整的
闭环控制; 3) 开发自适应基准值计算算法, 增强系
统对动态生产环境的适应能力; 4) 针对不同行业特
点, 构建可配置的模块化分析框架, 满足汽车电子、
医疗器械等细分领域的定制化需求。

参考文献:

[1] 夏鼎和 . 经济全球化背景下纺织工业产业结构的调整战略 [J]. 染整技术, 2024, 46 (5) : 17-19.
[2] HOSSAIN M T, SHAHID M A, LIMON M G M, et al. Techniques, Applications, and Challenges in Textiles for A Sustainable Future [J/OL]. Journal of Open Innovation: Technology, Market, and Complexity, 2024, 10 (1) : 100230[2025-08-28]. <https://doi.org/10.1016/j.joitmc.2024.100230>.
[3] 郑小虎, 刘正好, 陈峰, 等 . 纺织工业智能发展现状与展望 [J]. 纺织学报, 2023, 44 (8) : 205-216.
[4] 董奎勇 . 中国棉纺织工业发展历程与创新之路 [J]. 棉纺织技术, 2023, 51 (10) : 5-13.
[5] 张朝 . 人工智能时代制造业转型升级的四大路径 [J]. 中国工业和信息化, 2025 (6) : 42-47.
[6] 齐敬佩 . 检测报告和企业报表自动生成系统的设计与实现 [D]. 北京: 北京邮电大学, 2020.
[7] 欧佳乐, 咎红英, 张坤丽, 等 . 融合多视图特征的放射学报告生成 [J]. 计算机工程与应用, 2025, 61 (10) : 320-330.
[8] 刘李仕皓 . 食品安全抽检数据分析及报告智能生成系统 [D]. 北京: 北京林业大学, 2022.
[9] 姜磊 . 专用机械产品总装报告自动化生成系统开发 [J]. 机械工程师, 2021 (5) : 82-84.
[10] 鲁法明, 郑佳静, 包云霞, 等 . 基于锁增广分段图的多线程程序死锁检测 [J]. 软件学报, 2021, 32 (6) : 1682-1700.

作者简介: 孙平 (1972—), 女, 汉族, 福建福州人, 高级工程师, 学士, 研究方向: 工业互联网、知识图谱工业应用、标识解析应用。

(上接 70 页)

[5] 丁宁, 宋雨欣, 单泽田, 等 . 基于检索增强生成 (RAG) 技术的医学教学辅助智能问答系统的构建探索 [J]. 中国医学教育技术, 2025, 39 (1) : 1-5.
[6] 陆岫昶, 林娜, 骆永翰, 等 . Vue 支持下的多层次协同可视化前端设计 [J]. 电子设计工程, 2025, 33 (19) : 127-131.
[7] 陈迪欢, 陆希, 张耀峰 . 基于 LangChain+LLM 的招投标领域问答系统研究 [J]. 大数据时代, 2024 (5) : 23-28.

[8] 胡元江, 李严合 . 大语言模型的提示词模板架构及语言参数设定研究——以生成式新闻话语可读性为例 [J]. 外语学刊, 2025 (5) : 25-31.
[9] 邹聪, 张浩洋, 周浩 . 基于 Vue3 的数据申请管理系统设计与实现 [J]. 现代计算机, 2024, 30 (23) : 211-214.
[10] 杜豪天, 李一凡, 霍瑛, 等 . 改进 YOLOv5s 在钢材表面缺陷检测中的应用 [J]. 工业控制计算机, 2025, 38 (12) : 53-54, 57.

作者简介: 张宁 (1975.10—), 男, 汉族, 辽宁大连人, 讲师, 硕士研究生, 研究方向: 计算机应用。