

基于LangChain的张衡一号卫星 RAG问答系统的研发

张元敬¹ 李 忠¹ 黄建平² 泽仁志玛²

(1.防灾科技学院,河北 廊坊 065201;

2.国家自然灾害防治研究院,北京 100085)

摘 要:针对大语言模型在专业领域应用中存在的知识准确性不足、实时性欠缺和专业性局限等问题,提出了一种基于LangChain框架的张衡一号卫星电场数据RAG问答系统。通过融合RAG(Retrieval-Augmented Generation)技术与LLMs(Large Language Models)的推理能力,利用LangChain的模块化组件(包括LLMs接入、提示词模板和任务链编排)和Milvus向量数据库,实现了专业知识的动态检索与生成优化。实验数据来源于41篇张衡一号卫星电场领域的核心文献,涵盖电场异常检测、数据处理方法等研究方向。实验结果表明,相较于普通Qwen-Plus模型,RAG增强版本在科学参数描述和数据分析方法适用性方面展现出更优的专业性、实时性和准确性。这证实了RAG技术可有效解决LLMs在专业领域的知识局限性,为构建高可靠性的专业知识问答系统提供了可行的技术方案,具有重要的实践价值和理论意义。

关键词: LangChain; RAG; 张衡一号卫星; 问答系统

中图分类号: TP391.1

文献标志码: A

文章编号: 1008-6609(2025)08-0061-06

DOI:10.15966/j.cnki.dnydx.2025.08.002

1 引言

随着大语言模型(Large Language Models, LLMs)在自然语言处理任务中的广泛应用,其在专业领域应用的局限性也逐渐显现出来。LLMs的知识完全依赖于预训练阶段使用的公开数据集,这些数据集在准确性、专业性和实时性方面可能存在不足,导致模型在面对最新知识、专业术语或个性化上下文时,可能生成错误或过时的回答,即所谓的“幻觉”问题^[1]。

传统解决方案中较为常见的是微调,这一方法虽能拓展模型在专业领域的知识边界,但也面临高昂的计算成本、长周期训练以及动态知识更新困难等挑战。检索增强生成(Retrieval-Augmented Generation, RAG)技术通过动态检索外部知识库,为LLMs提供实时、精准的上下文,成为弥补其知识局限性的有效途径。

RAG技术在国内外均有着丰富的研究。在国内,蚂蚁集团提出了“GraphRAG”能够充分利用图数据中实体间的结构关系,更精准、全面地检索相关信息^[2]。在国外,华盛顿大学的Akari Asai等人提出了“Self-RAG”实现了自主检索决策^[3],

密歇根大学的团队提出了一种名为MRAG的多模态RAG框架,这种方案可以将多模态的数据(文本、图像、视频)集成到检索和生成过程中^[4]。

张衡一号卫星电场数据分析是一个专业性极强的领域,研究人员需要经常查阅大量资料来确定研究情况。如果仅凭借大语言模型的预训练知识库,无法做到科学准确。使用RAG技术将前人的研究内容作为知识图谱,支持大语言模型做出专业准确的回答,将会给数据分析人员的研究带来较大帮助。

2 基础知识介绍

2.1 LangChain框架

自2018年Transformer成功应用于自然语言处理任务以来,一系列的LLMs相继发布。在LLMs发展的同时,相应的LLMs应用技术也在逐步发展。LangChain是一个由大型语言模型驱动的应用程序框架,旨在简化LLMs的应用开发过程,提供了快速接入LLMs的模块,目前官方库和社区库支持几乎所有主流的LLMs,比如国内的Qwen系列大模型,国外的ChatGPT系列大模型等。LangChain还提供了便捷的提示

作者简介:张元敬(1999—),男,山东泰安人,硕士,研究方向为灾害信息处理技术。

基金项目:中央高校基本科研业务费研究生科技创新基金,项目编号:ZY20250333;河北省地震灾害仪器与监测技术重点实验室开放基金,项目编号:FZ224104。

词模板设计功能,通过简单的配置可以给 LLMs 提供 Prompt。Parser 是结果输出组件,它被设计用于接收 LLMs 发回的信息并解析为字符串格式。Chain 是 LangChain 的一个独特设计,它通过管道符“|”编排任务处理的工作链,将各个部分的功能添加在链中并按顺序实现。

通过以上组件的功能,LangChain 实现了简化 LLMs 应用开发的目标,使得用户可以通过对 Chain 的设计和组件创建,轻松地结合 LLMs 完成应用开发。

2.2 RAG 技术

2020 年 Facebook 人工智能团队首次提出了 RAG 这一概念^[1],通过将知识库信息检索与 LLMs 的逻辑推理能力结合起来,使得 LLMs 在回答用户需求方面更加准确。

RAG 技术具有三种范式,分别是朴素 RAG (NativeRAG)、高级 RAG (AdvancedRAG)和模块化 RAG (ModularRAG)[2-4]。朴素 RAG 技术的架构主要包含索引(Indexing)、检索(Retrieval)和生成(Generation)三个部分。索引部分,首先对 PDF、HTML、TXT、Word、Markdown 等格式的文件进行切分,需要保证的是切分的文本块能够支持嵌入模型的读取,嵌入模型在获取这些块之后会将其转换为高维向量存储到向量数据库中并建立索引。检索部分则是在用户查询时使用与索引阶段相同的嵌入模型,将用户的查询信息转换为向量,然后通过余弦相似度等方法与向量数据库中的文本向量进行对比计算得到一个相似度分数,系统会按照用户的设置,将相似度最高的前 K 个块输出,这些块就可以被用于组成 LLMs 的提示词。生成部分是用户的查询请求和检索得到的相关文本,被嵌入在 Prompt 中发送到 LLMs,LLMs 可以利用这些信息进行回答。对话过程中的问题和回答信息会被当作历史消息记录到 History 向量数据库中,这样可以给 LLMs 记忆功能使之可以与用户进行多轮对话。

2.3 Milvus 向量数据库

大语言模型(LLMs)在信息检索等任务中的兴起,以及电子商务和推荐平台等经济驱动力背后非结构化数据的增长^[5-6],促使研究人员开发了新的向量数据库(VDBs)及配套的管理系统(VDBMSs),以针对非结构化数据提供诸如查询优化、事务处理、可扩展性、容错能力以及隐私和安全等传统功能。向量数据库因其能管理传统数据库系统难以处理的高维数据而迅速崛起,现已与大语言模型深度整合并广泛应用于现代人工智能系统^[7]。过去 5 年内推出的比较流行的商业向量数据库有 20 余种^[8],下面以 Milvus 向量数据库为例进行介绍。

Milvus 的系统架构分为三个主要组件,查询引擎(Query Engine)、GPU 引擎(GPU Engine)、存储引擎(Storage Engine)。查询引擎组件优化了现代 CPU 的性能能够加速查询

处理,GPU 引擎支持 GPU 并行计算能力加速查询并且支持多 GPU 设备,通过混合索引(如 SQ8H)优化 CPU 和 GPU 的协同工作。存储引擎(Storage Engine)基于 LSM 树结构管理动态数据(插入、删除、更新),支持实时查询和快照隔离。数据以列式存储,支持本地文件系统、Amazon S3 和 HDFS 等多种存储后端。

2.4 张衡一号卫星电场知识图谱

2018 年 2 月 2 日中国自主研发的首颗地震电磁监测试验卫星——张衡一号卫星成功发射^[9-10],其共配置 8 种有效载荷:感应式磁力仪、高精度磁强计、电场探测仪、GNSS 掩星接收机、等离子体分析仪、朗缪尔探针、高能粒子探测器和三频信标机,目前已经运行 7 年多,卫星和载荷运行状态良好。基于张衡一号卫星采集的电离层数据,研究人员已经发表了几百篇相关论文和研究报告,其中很多发表在国际顶级的期刊上,论文质量优秀,具有很大的权威性。

本次研究的知识图谱收录 41 篇论文和说明文件,主要集中在张衡一号卫星科普介绍和电场领域论文,这些论文来自《中国科学》《遥感学报》《地球物理学报》《地球物理学进展》《Remote Sensing》等行业内重要期刊,涵盖了电场数据研究的大部分方向,能够为向量知识库提供优秀的知识图谱。

3 实验与结果评价

3.1 实验环境

系统环境:Windows10

软件环境:Python3.10、Conda、LangChain0.3.26、Docker

V28.2.2

硬件环境:CPU:I5-12600KF 内存:32 GB 硬盘:1T

大模型环境:Qwen-Plus、DeepSeek

开发环境:Cursor

3.2 实验过程说明

首先建立 Python 3.10 虚拟环境,安装 Numpy 等基础科学计算包,以及 LangChain 框架及其社区扩展包。采用 Docker 部署 Milvus 向量数据库用于存储和检索知识库的向量化表示。知识源数据为张衡一号卫星电场知识图谱,通过 DirectoryLoader 进行批量加载,并使用 CharacterTextSplitter 进行文本分割处理。使用向量嵌入模型将文本块转换为向量存储到 Milvus 向量数据库中。

向量数据库创建完毕后,需要创建一个 Chain 用于实现问答服务,这里 Chain 由以下几个组件构成:大模型(LLMs)、提示词模板(PromptTemplate)、收集文本块(collect_documents)和检索器(retriever)。

Chain 构建完成后需要与 get_redis_history(历史消息记录服务)组合构建一个 runnable,为 LLMs 提供历史消息记录服务。

最后在query中指定用户问题,通过runnable.invoke发送到LLMs并获得答案,进行多轮交流。

实验流程如图1所示,具体组件代码及其技术实现如表1所示。




图1 实验过程流程图

3.3 实验结果与分析

基于LangChain框架完成了RAG问答的实验阶段,使用一些张衡一号卫星的相关问题,分别对基于RAG的LLMs和普通LLMs进行问答实验。这里LLMs选用了Qwen-Plus,这是一个能力均衡的模型,推理效果、成本和速度介于Qwen Max和Qwen Turbo之间,适合中等复杂的任务。它在中英文能力、逻辑能力和多语言能力上有综合提升,尤其在数学、逻辑推理和知识问答等客观类任务中表现出色,实验中没有开启深度思考和联网搜索功能。两种问答实验对比结果如表2所示。

根据3个问答的对比,可以看到基于RAG的Qwen-Plus的回答比普通的Qwen-Plus的回答更加具体和专业。

对于“张衡一号卫星是什么?”问题的两种解答,普通的Qwen-Plus给出的答案中有“它以东汉科学家张衡命名,体现了对古代科技的致敬和现代地震科学研究的传承”。这是一个比较通俗的介绍,而在使用了RAG的Qwen-Plus中,详细介绍了张衡一号卫星的科学任务和运行轨道高度等专业参数,是一个比较专业的回答。

对于“张衡一号卫星的ULF电场波形数据是采集的具体哪个物理量?”问题的回答中,普通的Qwen-Plus回答的频率为“频率范围约为0.1 mHz到数Hz”。这是由于Qwen-Plus自身训练时的知识库并不准确造成,而使用了RAG的Qwen-Plus的回答中,详细介绍了ULF的频段范围和电场强度的三分量。

对于“张衡一号卫星的波形数据能否使用VMD和EMD方法分析?”的回答,使用RAG的Qwen-Plus对自身知识库中存在的EMD方法介绍了已有的研究,对于VMD能否用于数据分析的问题给出了“已知信息中未提及具体应用实例,因此无法确认是否适用于张衡一号卫星的波形数据分析”的回答。这符合提示词模板中要求LLMs只能从已知信息进行推理的限制,而普通的Qwen-Plus基于自身知识库覆盖范围较广的优势,给出了VMD能否用于张衡一号卫星波形数据分析的具体答案。

4 结论

在介绍LangChain技术、RAG技术、Milvus向量数据库和张衡一号卫星电场知识图谱的基础上,通过融合RAG技术与LLMs的推理能力,利用LangChain的模块化组件和Milvus向量数据库,构建了一种基于LangChain框架的张衡一号卫星电场数据RAG问答系统,实现了专业知识的动态检索与生成优化。得到以下两点结论:

(1)基于RAG技术的LLMs具有更高的专业性和准确性。该系统在回答问题时全部参考自高质量的、严谨的科研文章,有效避免了普通LLMs使用预训练知识库可能存在的知识错误和回答外行的问题,大大提高了答案质量。

(2)该系统的知识库具有实时性。LLMs的知识库从预训练知识库转到了本地专业知识库,开发者可以操作本地数据库以更新专业知识图谱,从而保证了LLMs知识库的实时性。

参考文献:

- [1] Huang L, Yu W, Ma W, et al. A survey on hallucination in large language models: Principles, taxonomy, chal-

表1 实验核心组件代码及其技术实现细节

组件名称	具体实现	核心代码	功能描述
文本分割器	CharacterTextSplitter	text_splitter=CharacterTextSplitter(chunk_size=1000,chunk_overlap=200)	将 PDF 文档内容分割为适当大小的文本块,保留重叠部分确保语义连贯性
向量嵌入模型	DashScopeEmbeddings	embedding_model=DashScopeEmbeddings(model="text-embedding-v3", dashscope_api_key=key1)	将文本块转化为高维向量表示,支持语义相似度计算
向量数据库	MilvusVectorStore	vector_store=Milvus.from_documents(documents=split_docs, embedding=embedding_model, connection_args={"host":"localhost","port":19530}, collection_name="zhangheng_knowledge")	存储向量化文本块并支持高效相似度检索
历史记录服务	RedisChatMessageHistory	def get_redis_history(session_id: str): return RedisChatMessageHistory(session_id=session_id, url="redis://localhost:6379/1", key_prefix="zh_chat:", ttl=timedelta(days=1))	使用 redis 数据库维护对话上下文,支持多轮对话连贯性
检索实现	Vector_Store	vector_store=RedisVectorStore(embedding_model, config=config) retriever=vector_store.as_retriever(search_kwargs={"k":15})	使用相同的向量嵌入模型对问题进行向量化从而与向量数据库中的数据计算相似度返回前 15 条相似信息
工作链	Chain	chain = { "context": itemgetter("question") retriever format_documents, "question": itemgetter("question"), "history": itemgetter("history") } prompt_template llm StrOutputParser()	通过管道符“ ”实现数据流式处理
运行器	Runnable	runnable=RunnableWithMessageHistory(chain, get_session_history=get_redis_history, input_messages_key="question", history_messages_key="history")	将数据流式处理的链以及历史对话记录集成形成运行器
问答交流	Query	for query in queries: result = runnable.invoke({"question":query}, config= {"configurable": {"session_id": session_id}}) print(f"Q: {query}\nA: {result}\n")	将问题填写在“query”中,运行此程序即可进行问答交流

表2 问答实验对比结果

用户问题	RAG+Qwen-Plus 的回答	Qwen-Plus 的回答
张衡一号卫星是什么？	张衡一号卫星是中国首颗专用于监测电离层电磁变化的卫星，也被称为电磁监测试验卫星（China Seismo-Electromagnetic Satellite, CSES），于2018年2月2日成功发射。它由中国研制，旨在通过监测电离层中的等离子体、高能粒子以及地球物理场信息来探测地震前兆信息，并为空间环境的监测预报提供重要数据。该卫星运行在高度约507公里的太阳同步轨道上，轨道倾角为97.4°，其主要科学任务包括研究地震相关的电离层扰动、空间天气变化以及探索地球内部结构和演化过程等。	“张衡一号”是中国首颗地震电磁监测卫星，于2018年2月2日发射，主要用于探测地震前后地球电磁环境的变化，探索地震前兆信号，提升地震预测水平。卫星搭载多种科学载荷，运行在500公里高的太阳同步轨道，设计寿命5年。它以东汉科学家张衡命名，体现了对古代科技的致敬和现代地震科学研究的传承。
张衡一号卫星的ULF电场波形数据是采集的具体哪个物理量？	张衡一号卫星的ULF电场波形数据采集的是空间电场强度的三分量(X、Y、Z)信息。这些数据反映了在ULF频段下(0~16 Hz)，沿地理坐标系三个正交方向的空间电场随时间变化的特性。	“张衡一号”卫星的ULF电场波形数据采集的是空间环境中三维电场强度随时间变化的低频波动信号(频率范围约为0.1 mHz到数Hz)，用于研究地震前兆电磁异常和空间物理过程。
张衡一号卫星的波形数据能否使用VMD和EMD方法分析？	张衡一号卫星的波形数据可以使用EMD(经验模态分解)方法进行分析。已有研究表明,EMD方法被用于处理张衡一号卫星电场ULF频段数据,通过重构信号消除了原信号的电场趋势,并从时域角度刻画了信号的变化特征。至于VMD(变分模态分解)方法,已知信息中未提及具体应用实例,因此无法确认是否适用于张衡一号卫星的波形数据分析。	是的,“张衡一号”卫星的波形数据可以使用VMD(变分模态分解)和EMD(经验模态分解)方法进行分析。这两种方法适用于处理非线性和非平稳信号,能够有效提取电磁波形中的特征频率和异常波动,有助于识别地震前兆信号和分析空间电磁环境变化。

lenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.

[2] Peng B, Zhu Y, Liu Y, et al. Graph retrieval-augmented generation: A survey[J]. arXiv preprint arXiv: 2408. 08921, 2024.

[3] Asai A, Wu Z, Wang Y, et al. Self-rag: Learning to retrieve, generate, and critique through self-reflection[C]//The Twelfth International Conference on Learning Representations. 2023.

[4] Mei L, Mo S, Yang Z, et al. A survey of multimodal retrieval-augmented generation[J]. arXiv preprint arXiv: 2504. 08748, 2025.

[5] Fan W, Ding Y, Ning L, et al. A survey on rag meeting LLMs: Towards retrieval-augmented large language models [C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 6491-6501.

[6] Zhao P, Zhang H, Yu Q, et al. Retrieval-augmented generation for ai-generated content: A survey[J]. arXiv preprint arXiv: 2402. 19473, 2024.

[7] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv: 2312. 10997, 2023, 2(1).

[8] Fan W, Ding Y, Ning L, et al. A survey on rag meeting llms: Towards retrieval-augmented large language models [C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 6491-6501.

[9] 黄建平, 张富志, 李忠, 等. 张衡一号卫星观测的震前电场数据扰动识别研究[J]. 中国科学: 地球科学, 2023, 53(8): 1834-1843.

[10] Zhima Z, Dapeng L, Xiaoying S, et al. Current status and scientific progress of the Zhangheng-1 satellite mission[J]. Reviews of Geophysics and Planetary Physics, 2023, 54(4): 455-465.

Research on the Zhangheng-1 Satellite RAG Question Answering System Based on LangChain

ZHANG Yuan-jing¹ LI Zhong¹ HUANG Jian-ping² ZEREN Zhi-ma²

(1. Institute of Disaster Prevention, Langfang Hebei, 065201;

2. National Institute of Natural Hazards, Beijing, 100085)

Abstract: In view of the problems of insufficient knowledge accuracy, lack of real-time performance and professional limitations in the application of large language models (LLMs) in professional fields, this study proposes a retrieval-augmented generation (RAG) question-answering system based on the LangChain framework and the Zhangheng-1 satellite electric field knowledge graph. By integrating the reasoning ability of RAG technology and LLMs, and using LangChain's modular components (including LLMs access, prompt word templates and task chain orchestration) and Milvus vector database, dynamic retrieval and generation optimization of professional knowledge are achieved. The experimental data comes from 41 core papers in the field of Zhangheng-1 satellite electric field, covering research directions such as electric field anomaly detection and data processing methods. The test results show that compared with the ordinary Qwen-Plus model, the enhanced version of RAG shows better professionalism and accuracy in scientific parameter description and method applicability analysis. The study confirms that RAG technology can effectively solve the knowledge limitations of LLMs in professional fields and provide a feasible technical solution for building a highly reliable professional knowledge question-answering system, which has important theoretical value and practical significance.

Keywords: LangChain; RAG; Zhangheng-1 satellite; question-answering system

(上接第 47 页)

Design of a Compact Broadband Bandpass Filter with Multiple Transmission Zeros Based on Parallel-Coupled Lines

CHEN Pu-shen¹ WU Chen-cheng² MA Ke-xin² WEI Cheng² CHENG Yong^{3*}

(1. Portland institute, Nanjing University of Post and Telecommunications, Nanjing 210046, China;

2. College of Electronic and Optical Engineering & College of Flexible Electronics (Future Technology), Nanjing University of Post and Telecommunications, Nanjing 210046, China;

3. Department of Engineering Experiments and Innovations Nanjing University of Post and Telecommunications, Nanjing 210046, China)

Abstract: Compact broadband multi-zero bandpass filters (BPFs) demonstrate superior performance including wide bandwidth, high selectivity, and sharp out-of-band rejection. By employing multi-mode resonance and hybrid structure designs, these filters enhance nonlinear response and interference suppression, achieving ultra-wideband operation (>100% relative bandwidth) while maintaining excellent stopband performance. This paper presents a compact broadband bandpass filter design with multiple transmission zeros based on a parallel-coupled line structure. The proposed design employs a novel cascaded compact coupled-line structure with a wide stopband, achieving multiple transmission zeros while maintaining broadband characteristics, thereby effectively extending the stopband bandwidth. The research includes: analysis of the filter's resonance mechanism and transmission zero characteristics, parameter sensitivity study, electromagnetic simulation modeling, and optimization. The final measured results demonstrate a return loss better than 10 dB within the 3.5 GHz ~ 6.5 GHz frequency band, an insertion loss of approximately 0.29 dB at the center frequency, a 3-dB fractional bandwidth (FBW) of 91.2%, and an out-of-band suppression of 20 dB at four times the center frequency (20 GHz).

Keywords: ultra-wideband; phase shifter; filter; miniaturization; parallel-coupled line; wide stop-band