

基于LangChain的智慧建筑专家客服系统的构建探究

吴文艺* 杨雪毅 张恒

贵阳信息科技学院 贵州贵阳 550025



摘要: 随着人工智能技术的快速发展,智慧建筑领域对专家客服系统的需求日益增长。介绍了一种基于人工智能生成内容(Artificial Intelligence Generated Content,AIGC)的垂直领域机器人——智慧建筑专家客服系统的应用实现。该系统利用LangChain框架,以DeepSeek-R1-Distill-Qwen-1.5B为大语音模型(Large Language Model,LLM)基座模型,结合向量数据库和文本向量化模型,以最低的代码量实现了系统的快速搭建。该系统不仅易于实现,还具有维护简单、更新便捷、开发成本低等优势,特别适合迭代中的中小型智慧建筑系统。

关键词: LangChain框架 DeepSeek-R1 向量数据库 专家客服系统

中图分类号: TP311

文献标识码: A

文章编号: 1672-3791(2026)01-0050-03

Exploration of the Construction of an Intelligent Architecture Expert Customer Service System Based on LangChain

WU Wenyi* YANG Xueyi ZHANG Heng

Guizhou Institute of Information Science and Technology, Guiyang, Guizhou Province, 550025 China

Abstract: With the rapid development of Artificial Intelligence (AI) technology, the demand for expert customer service systems in smart buildings has been increasing. This paper introduces the implementation of a vertical-domain robot based on Artificial Intelligence Generated Content (AIGC)—a smart building expert customer service system. The system utilizes the LangChain framework, with DeepSeek-R1-Distill-Qwen-1.5B as the base Large Language Model (LLM), combined with a vector database and a text vectorization model, enabling rapid system deployment with minimal code. The system is not only easy to implement but also offers advantages such as simple maintenance, convenient updates, and low development costs, making it particularly suitable for small and medium-sized smart building systems undergoing iteration.

Keywords: LangChain framework; DeepSeek-R1; Vector database; Expert customer service

传统的专家客服系统在迭代过程中往往面临高昂的开发和维护成本,尤其是基于知识图谱的系统。大规模的智慧建筑系统由中小型智慧建筑系统扩展而来,与之相配的专家客服系统也经历数次迭代才有最终版本。为显著减少迭代工作量且无须对历史数据进行复杂处理,在无须代码修改的情况下,自动回答更新

后的指定领域答案。这一方案为智慧建筑系统的标配化提供了可行路径,使专家客服系统能够轻松适配不同规模的智慧建筑系统,降低开发与维护成本,推动智慧建筑领域的智能化进程。

1 系统框架

如何降低专家客服系统的开发与维护成本成为其

通信作者: 吴文艺(1992—),男,本科,工程师,研究方向为软件理论与应用。E-mail: 1247823556@qq.com。

能否为智慧建筑系统标配子系统的关键因素。从根本上探索一种更为高效的实现方案,以减少开发与维护成本,以及设计一种简约的导入模块和一种基于导入数据的问答模块。为了实现专家客服系统的高效开发与维护,并降低其成本,引入了LangChain这一先进技术,结合向量数据库技术,构建了一个基于人工智能生成内容(Artificial Intelligence Generated Content, AIGC)的客服专家机器人架构^[1]。这种基于AIGC的架构设计具有显著优势。一方面,它能够充分利用AIGC的强大生成能力,自动产生高质量的回答,减少了人工干预的成本^[2]。另一方面,低代码特性使系统在开发和维护过程中更加便捷,经过配置和调整,就能快速搭建一个功能完善的客服专家系统^[3]。

2 相关技术与实现

2.1 LangChain简介与使用

LangChain是一个基于大语言模型(Large Language Model, LLM)用于构建端到端语言模型应用的框架,可

以提供开箱即用的功能支持^[4],可以连接到各种数据与计算源,并构建在特定领域数据源、私有存储库等之上执行自然语言处理任务的应用程序,为各种不同基础模型提供统一接口。LangChain有六大核心模块,如表1所示。

表1 LangChain的六大功能模块

模块名	功能
Models	为各种不同基础模型提供统一接口(从不同的LLM和嵌入模型中进行选择)
Prompts	为各种不同基础模型提供统一接口(管理LLM输入)
Chains	将LLM与其他组件相结合
Indexes	访问外部数据
Memory	记住以前的对话
Agents	访问其他工具

除表1中六大模块以外,整个问答机器人模块中,使用的LangChain模块与子模块如表2所示。

表2 问答机器人模块中使用的子模块

模块名称	对应子模块	对应智慧建筑专家客服系统功能
langchain.llms.base	LLM	实例化DeepSeek-R1-Distill-Qwen-1.5B
langchain.embeddings	HuggingFaceEmbeddings	加载向量模型,生成embeddings实例
langchain.vectorstores	Qdrant	连接本地Qdrant数据库
langchain.chains	RetrievalQA	实现问答器实例
langchain.memory	ConversationBufferMemory	设置将历史答案与问题保留在内存

2.2 DeepSeek-R1-Distill-Qwen-1.5B

DeepSeek-R1-Distill-Qwen-1.5B是深度求索公司的一个轻量级且高效的自然语言处理模型,基于蒸馏技术从更大规模的预训练模型中提取核心知识,兼具高性能与低资源消耗的特点^[5]。该模型在语义理解、文本生成和问答任务中表现出色,尤其适合资源受限的场景。

2.3 数据导入模块

数据导入模块的功能主要是接收文档数据,使用文本向量化模型Text2vec处理格式繁多且不统一的各类语料文档,处理方式是将文件中的文本进行分块,然后将文本(包括词、句子、段落)向量化,表征为向量矩阵,并将这些矩阵嵌入embedding到向量数据库Qdrant中,形成一个本地知识库,与问答机器人模块通过本地向量数据库协同工作。

2.4 问答机器人模块

问答机器人模块负责从数据库中查询数据,是整

个系统的核心模块,是与用户交互的窗口。在问答流程中,使用LangChain来融合向量化模型、向量数据库和LLM。实现关键代码见图1。

3 实现效果

3.1 系统运行效果

系统的智能问答功能有着灵活的双重机制:当专家领域语料不足时,系统可以直接调用模型生成回答,从而避免因数据缺失而导致服务中断。此外,当向量数据库中缺乏相关数据时,系统也能够结合大模型的生成能力,提供更合理的回答。

3.2 系统运行情况

在系统的测试与部署阶段,基于表3所列的软硬件资源进行了全面验证。在此配置下,图2、图3分别展示了系统运行时处理器和网络传输的状态。从处理器、网络传输效率等负荷运行的体现数据来看,系统资源分配很均衡——显卡大部分时间高效工作,内存和处理器的占用也都在正常范围内,没有出现卡顿或资源不足的问题。

```
### 编写DeepSeek类
class DeepSeek (LLM):
    # 属性略
    def __init__(self):
        super().__init__()
    @property
    def _llm_type(self) -> str:
        return "DeepSeek"
    def load_model(self, llm_device="gpu",model_name_or_path=None):
        model_config = AutoConfig.from_pretrained( ... )
        self.tokenizer = AutoTokenizer.from_pretrained( ... )
        self.model = AutoModel.from_pretrained( ... ).half().cuda()
        #重写 _call方法: 加载自己的模型, 并限制只输出结果
    def _call(self,prompt:str,history:List[str] = [],stop: Optional[List[str]] = None):
        ...
        return response
    def get_model():# 实例化LLM# 调用DeepSeek-R1-Distill-Qwen-1.5B
        modelpath = "/gemini/data-2/DeepSeek-R1-Distill-Qwen-1.5B "
        sys.path.append(modelpath)
        llm = GLM()
        llm.load_model(model_name_or_path = modelpath)
        # 连接向量数据库 略
        ## 加载向量化模型 略
```

图1 实现关键代码(部分)

表3 开发与运行系统软硬件资源

资源名称	参数
GPU	1gpu(s), 每个GPU 显存:24 GB
CPU	8core(s)
内存	24 GB
OS、AI计算框架、Python版本	ubuntu20.04、PyTorch 2.0.0、python3.9




图2 处理器运行体现(时段抽样)




图3 网络 I/O 传输率(时段抽样)

4 结语

本研究通过研究 LangChain 框架,结合向量数据库

技术和 DeepSeek-R1-Distill-Qwen-1.5B 大语言模型,成功实现了一个低代码、易维护的智慧建筑专家客服系统。该系统不仅显著降低了开发与维护成本,还具备良好的扩展性和适应性,能够满足不同规模智慧建筑系统的需求。相较于传统开发方式,本方案节省了大量人力、时间和经济成本,为中小型企业提供了一条高效的技术路径。

参考文献

[1] 周鹏,刘晓蒙.关注向量数据库技术与产业发展及相关建议[J].中国信息化,2024(10):62-64.

[2] 李白杨,白云,詹希旎,等.人工智能生成内容(AIGC)的技术特征与形态演进[J].图书情报知识,2023,40(1):66-74.

[3] 李梅,陈晓娜,李珂.基于低代码平台的业务流程设计与应用实践[J].科技创新与应用,2024,14(34):52-58,62.

[4] 陈迪欢,陆希,张耀峰.基于 LangChain+LLM 的招投标领域问答系统研究[J].大数据时代,2024(5):23-28.

[5] 佚名.开源 AI 模型 DeepSeek-R1 引发全球科技界关注[J].科技导报,2025,43(3):7.