

基于 LLM 和 RAG 的人才政策智能问答系统研究

在人工智能技术迅猛发展的今天，如何提升政策咨询的效率和用户体验显得至关重要。本研究提出了一套基于大语言模型 (LLM) 和检索增强生成 (RAG) 技术的人才政策智能问答系统，旨在解决当前政策咨询中的诸多问题。文章详细介绍了系统的总体架构和处理流程。通过结合 LangChain 框架，该系统实现了高效的信息检索和回答生成。用户测试和对比分析结果表明，该系统在性能、回答准确性和用户满意度方面表现出色。

文 | 黄梦迪 杭州市数据集团有限公司 陈敏 蚂蚁智信科技有限公司

一、引言

人才政策在现代社会中至关重要，影响地区的经济发展、科技创新和社会进步。2021 年，中共中央、国务院出台了《关于支持浙江高质量发展建设共同富裕示范区的意见》，明确提出实行更加开放的人才政策，激发人才创新活力。对此，杭州市委、杭州市政府积极响应国家政策，深入贯彻人才强国战略，高度重视人才工作，不断迭代升级人才政策。自 2015 年以来，杭州市每年都出台新的人才政策，以适应不断变化的发展需求。

然而，随着人才政策的不断增多，用户难以快速找到所需信息。当前的人才政策咨询方式仍存在诸多问题，如信息获取不便、咨询过程烦琐、人工成本高昂等，

在一定程度上阻碍了人才政策的有效实施和推广。

随着人工智能技术的迅猛发展，大语言模型 (LLM) 在多个领域展现了重要作用，尤其在智能问答中表现出强大能力，能够快速、准确地理解用户问题并生成高质量、上下文相关的答案。检索增强生成 (RAG) 技术通过从大量文档中检索相关信息，再由大语言模型整合生成答案，进一步确保回答的准确性和全面性。

本研究旨在响应政府对高效政策咨询的需求，利用 LLM 和 RAG 技术构建人才政策智能问答系统，帮助用户快速了解各类人才政策，减轻客服人员的负担，提升政策咨询效率和用户满意度。



赛迪网官方微信



数字经济官方微信

二、相关技术研究

(一) 大语言模型

大语言模型 (Large Language Model, LLM) 是基于深度学习技术的大规模神经网络模型, 旨在理解和生成自然语言。他们通常包含数千亿甚至更多的参数, 从海量数据上训练获得。大语言模型在自然语言处理 (NLP) 方面表现出色, 能够捕捉语言的复杂性和多样性, 从而进行文本生成、翻译、问答等任务。代表性模型包括国外的 OpenAI 的 GPT 系列、Meta 的 LLaMA 以及国内阿里的通义千问、智谱的 ChatGLM 等。

(二) 检索增强生成技术

检索增强生成技术 (Retrieval-Augmented Generation, RAG) 是一种结合信息检索和生成模型的技术, 旨在提升生成式大语言模型的回答质量和准确性。其原理是将文档分割成小片段并进行向量化表示, 以捕捉语义信息。在生成阶段, 通过计算 embedding 相似度, 从文档库中检索出与查询最相关的片段, 并与查询一起输入大语言模型生成最终回答。RAG 技术弥补了大语言模型在特定领域知识上的不足, 在问答系统、对话

系统、信息摘要和知识提取等领域表现出色。

(三) LangChain 框架

LangChain 是一个专为构建基于语言模型的应用程序而设计的开源框架, 旨在简化自然语言处理任务的开发。他提供一系列模块化的组件, 如文本生成、信息检索和对话管理等, 并通过链式结构将这些组件连接起来, 使得开发者可以轻松地组合和扩展不同的功能。

三、系统架构设计

(一) 系统总体架构介绍

人才政策智能问答系统框架包括基础设施层、数据层、模型层、技术层和应用层五个层次。

基础设施层提供计算和存储等资源, 包括 GPU 和 CPU 用于处理计算任务, 磁盘用于存储数据, 网络通信用于数据传输和设备连接。数据层负责存储和管理各类数据, 为上层的模型和应用提供了基础信息和上下文支持。模型层是智能问答系统的关键, 包括大语言模型 (LLM) 和 embedding 模型。大语言模型 (LLM) 能够理解和生成自然语言, 提

表 1 不同数据类别示例

数据类别	示例内容
政策文件	《杭州市高层次人才分类认定办法 (试行)》《关于规范〈杭州市留学回国人员工作证〉办理工作的通知》
术语解读	高层次人才、青荷礼包、杭州人才码
常见问答	问题: 杭州市应届大学生租房补贴每年发放多少元?

来源: 杭州市数据集团有限公司




图 1 系统流程处理图

供智能问答、对话和文本生成等功能，而 embedding 模型将数据转换为向量表示，通过相似性计算和语义匹配，找到最相关内容注入大语言模型。技术层提供具体功能的技术支持，包括向量化存储、提示工程、生成问答等，帮助系统高效处理数据和提供智能化服务。应用层是用户直接交互部分，封装底层技术和模型功能，提供易用服务和工具。

（二）人才政策数据介绍

本研究所用的原始数据来源于政府网站和相关机构的公开发布，涵盖上千条政策信息，包括政策文件、术语解读和常见问答等内容，涉及人才优惠政策、认定流程、申请步骤及所需材料等，全面覆盖落户、安居保障、创业就业、旅游交通等多个方面。

（三）系统处理流程

本研究选择 Qwen 系列 72B 模型，并

采用 vLLM 进行部署，以确保模型在中文处理方面的高效运行。部署完成后，使用 LangChain 框架进行接口调用，实现了高效和便捷的模型交互。

图 1 展示了系统完整的处理流程，用户问题会经过标准化和向量化、语义相似度检索、提示工程等步骤，最终利用大语言模型生成回答。

RAG 实现

在实现 RAG 模块时，我们利用了 LangChain 框架的工具和组件，简化实现过程并提升系统性能。首先，使用 PyPDFLoader 工具包提取 PDF 或文档中的文本和表格数据。然后，提取每个文档的标题和章节名称，并将内容切分成与标题或章节名称对应的键值对进行存储。接着，通过 embedding 模型如 bge，将文本转换为数值形式的向量，将这些向量及其元数据存储到 Redis 中，并创

建索引以便快速检索相似向量。通过以上步骤，最终完成向量知识库的构建。

为了提高检索的匹配度，我们结合用户的历史对话，利用大语言模型重写用户问题，识别出关键意图，消除歧义，使问题表达更清晰。然后，将重写后的问题输入 embedding 模型转换为向量表示，来捕捉用户问题中的语义信息。通过与向量知识库中的向量比较，计算语义相似度，检索相关文档片段。

此外，采用多路召回机制，使用不同类型的知识和检索策略对知识库进行查询，以最大化检索覆盖范围。对检索到的结果根据语义相似度筛选和重新排序，确保返回最相关的文档片段。

生成问答

在问答生成过程中，通过提示工程引导模型生成高质量回答，设计合适输入模板并设定客服口吻，提升模型对用户意图的理解。同时，系统会记录并管理用户历史对话。每次新对话时，系统检索用户历史对话记录，将重要信息与 RAG 模块检索出的知识整合，注入大语言模型，提供全面准确的回答。

系统可扩展性与用户体验

考虑到系统的可扩展性和维护性，我们增加了后台管理系统，便于快速嵌入新文档内容。同时提供可视化交互界面，使用户能方便地输入问题并获取回答，以进一步提升用户体验。

四、效果分析

为了全面评估人才政策智能问答系统的效果，我们进行了多次用户测试和

对比分析。结果显示，系统的平均响应时间为 1 ~ 2 秒，显著优于传统人工客服的 30 秒 ~ 1 分钟，极大缩短了用户等待时间。在高并发情况下，系统依然稳定运行。回答准确性方面，系统的正确率超过 90%。在处理常见问题和政策细节时，系统能够提供准确且详细的回答，并根据上下文提供附加信息。例如，当用户询问“如何申请高层次人才认定”时，系统不仅提供了详细的申请流程，还补充了所需材料的信息。我们增加了用户满意度调查功能。统计数据显示：85% 的用户对系统回答的准确性表示满意。从整体来看，人才政策智能问答系统在系统性能、回答准确性和用户满意度方面表现出色，显著提升了政策咨询效率和用户体验。与人工客服相比，人才政策智能问答系统在响应速度、回答质量和成本效益方面展现出优势，能更好地满足用户咨询需求。

五、结束语

本文研究了利用开源大语言模型（LLM）和检索增强生成（RAG）技术构建人才政策智能问答系统的可行性和实际效果。结果表明，该系统显著提升了政策咨询的效率和用户体验。希望这些研究成果和方法能够为其他领域的智能问答系统开发提供参考。

责任编辑：徐培炎 投稿邮箱 zhouhl@staff.ccidnet.com