

大模型检索增强生成（RAG）技术浅析

文 | 国网思极网安科技（北京）有限公司 赵静 汤文玉 霍钰 傅金菲菲 乔芷琪

近年来，随着A2大模型的飞速发展，自然语言处理（NLP）领域也迎来了许多创新性的突破。其中，检索增强生成（Retrieval-Augmented Generation, RAG）技术作为一种新兴的技术范式，受到了广泛关注和研究。本文将对RAG技术的基本概念、架构设计、应用及其优势进行详细探讨，并结合相关文献讲述其发展历程和未来研究方向。

一、基本概念与架构

检索增强生成是一种结合了信息检索和生成模型的技术，旨在通过引入外部知识库的信息来辅助大语言模型（Large Language Models, LLMs）生成更准确且符合上下文的答案。具体来说，当大模型需要生成文本或回答问题时，它会先从一个庞大的文档集合中检索出相关信息，然后利用这些检索到的信息来指导文本的生成。

RAG架构主要分为三个模块，如图1所示。

1) 索引器（Indexing）：索引是检索过程的基础，

它将文本转换为向量表示并存储在向量数据库中，以便快速检索。高效的索引方法对于提升整体性能至关重要。

2) 检索器（Retriever）：检索器负责从大规模文档集合中检索相关信息。常见的检索器包括基于向量的检索方法（如BM25、DPR）和深度学习检索方法。

3) 生成器（Generator）：生成器基于检索到的信息生成文本。大多数情况下，生成器采用先进的语言模型，如GPT系列模型，以确保生成内容的连贯性和准确性。

二、RAG的工作流程

RAG的工作流程是将信息检索技术与文本生成技术相结合，以提高生成文本的准确性和丰富性。RAG工作流程如图2所示。

1) 数据预处理（Data Preprocessing）：对原始数据进行清洗，包括去除无关内容、格式化等。将数据转换为适合处理的格式，如文本数据的分词、去除停用词等。

2) 文档索引化（Document Indexing）：将处理后的数据分割成小块（Chunks），以适应模型的输入要求。使用编码器（如Transformer的Encoder）将文




图1 RAG架构




图2 RAG的工作流程

本块转换为向量形式。建立索引，将文本块的向量存储在可检索的数据库中。

3) 查询理解 (Query Understanding)：用户提出问题或请求，系统首先需要理解查询的意图。

4) 查询向量化 (Query Embedding)：使用与索引阶段相同的编码器将用户查询转换为向量形式。

5) 检索 (Retrieval)：利用查询向量在索引数据库中检索最相关的文档块。通常采用相似度度量（如余弦相似度）来评估相关性。

6) 文档重排序 (Re-ranking)：可选步骤，对检索到的文档块进行重排序，以优化结果的相关性。

7) 上下文融合 (Context Fusion)：将检索到的文档块与原始查询结合，形成丰富的上下文信息。

8) 生成 (Generation)：使用生成模型（如大

型语言模型）根据融合后的上下文信息生成回答或文本。

9) 后处理 (Post-processing)：对生成的文本进行语法检查、错误修正等，以提高文本质量。

10) 输出结果 (Result Output)：将最终生成的文本作为回答输出给用户。

三、RAG的发展和分类

RAG的发展可以分为三个主要阶段：原始RAG (Naive RAG)、高级RAG (Advanced RAG) 和模块化RAG (Modular RAG)。每个阶段都在不断改进模型的性能和适用范围。

原始RAG是RAG技术发展初期的一个基础形态，它以一种相对简单直接的方式，结合了检索和生成两个步骤来增强语言模型的输出。Naive RAG的架构和流程相对简单，易于理解和实现，是RAG技术的起点。生成的回答质量在很大程度上依赖于检索阶段的效果，如果检索到的文本块与查询不够相关，可能会导致生成的回答质量下降。在生成阶段，如果检索到的多个文本块包含相似或重复的信息，可能会导致生成的回答中出现冗余内容。尽管Naive RAG存在一些局限性，但它为后续更高级的RAG技术发展奠定了基础，并且其简单性也使得它在一些应用场景下仍然具有一定的实用价值。

高级RAG是在Naive RAG的基础上发展起来的更高级的RAG技术范式。它通过引入更复杂的策略和技术来优化检索和生成过程，以提高整体性能和输出质量。高级RAG在索引阶段进行了优化，可能会采用更细粒度的文本分块，例如基于句子或短语的分块，以提高检索的精确度。在检索之前，高级RAG可能会对用户查询进行改写或扩展，以更好地匹配文档库中的内容。高级RAG通过引入多种高级技术和策略，显著提高了RAG技术的性能和应用范围，使其在复杂的自然语言处理任务中更加有效和可靠。随着研究的深入，高级RAG仍在不断发展，以解决更多的挑战和需求。

(下转70页)

表1 计算机科学与技术专业产教融合指标体系评价结果

一级指标	得分	二级指标	比例	得分
效果指标	74.4	学校效益	20%	71.56
		教学成果应用	40%	61.56
		学生发展	40%	88.65
过程指标	78.02	师生认知态度	15%	61.39
		教学方法和考核方式	35%	77.56
		学生学习情况	50%	83.34
资源配置	70.8	经费投入	30%	68.23
		制度建设	10%	86.67
		师资队伍	25%	70.56
		实训基地	30%	80.08
保障措施	87.46	政策支持	65%	88.15
		组织机构	25%	87.34
		环境氛围	10%	83.24

（三）通过评价反馈，持续改进实践教学

针对基于CIPP的计算机专业实践教学评价结果，专业建设工作小组将评价结果反馈给相关环节的负责人，如院校教学管理部门、专业负责人、实践教学课程组等，作为对院校实践教学制度修订、专业实践课程体系、实践课程内容、实践教学模式等各方面持续改进的依据。

专业建设工作小组收集各相关环节的反馈意见，从教育环境、资源配置、实施情况、实施效果整理出相关改进措施。从学校层面建立健全实践教学管理长效机制，根据管理机制定期对实践教学进行检查评估，根据反馈调整对实践教学活动的经费支持，确保实践教学的质量和效果。

四、小结

通过实施“两融一贯穿”实践教学和“四维融通”实践教学评价，不断优化和改进实践教学全过程，提高学生学习效果和实践能力，提升创新人才培养质量。近5年，河北工程大学计算机科学与技术专业毕业生工作与专业相关度较高，对工作具有较高的适应性，受到用人单位一致好评。涌现出一批优秀校友，就业于阿里巴巴、京东等代表性企业，毕业生为区域发展奠定了坚实的力量。

（上接72页）

模块化RAG是一种更灵活和高级的RAG技术范式，它通过将RAG技术分解为多个可替换和可组合的模块来增强其灵活性和适应性。模块化RAG将RAG技术分解为多个独立的模块，每个模块负责特定的任务，如索引创建、检索、生成等。模块化RAG支持多任务学习和多模态检索，能够处理文本、图像、视频等多种类型的数据，并在多个任务上进行优化。模块化RAG的模块可以协同工作，通过模块间的交互和数据交换，实现更复杂的功能和更高效的处理。模块化RAG通过其模块化设计，提供了一种灵活、可扩展且适应性强的RAG技术范式，使其在复杂的自然语言处理任务中更加有效和可靠。随着技术的不断发展，模块化RAG将继续在更多领域和任务中发挥重要作用。

四、未来展望

根据现状，未来针对RAG的研究可能会集中在以下几个方面：一是优化计算资源利用：通过算法优化和硬件加速技术，降低RAG模型的计算成本。二是实时信息更新：开发更高效的外部知识库更新机制，确保生成内容的时效性和准确性。三是跨模态应用：探索RAG在图像、视频等多模态数据上的应用潜力。

检索增强生成技术作为一种前沿的大模型技术，通过结合信息检索和生成模型的优势，显著提升了大语言模型的生成质量和理解能力。尽管检索增强生成技术仍面临一些挑战，但其广阔的应用前景和持续的技术进步，预示着其将在未来的自然语言处理领域发挥越来越重要的作用。